

CC-0F4

Ecuaciones esenciales


Semana 1

Transformers, atención, causalidad y arquitecturas

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V$$

1. Del modelo al sistema


Primero separamos la función matemática del sistema que la rodea.



Lectura: una ecuación puede describir el modelo, pero no describe por sí sola el sistema completo.

2. De tokens a una matriz de representaciones

Cada posición termina representada por un vector de dimensión d_{model} .



T filas = T posiciones

d_{model} columnas =
características

La posición rompe la simetría
del orden

Lectura: X tiene una fila por token y d_{model} características por representación.

3. Qué significa comparar estrategias posicionales

Dos preguntas experimentales distintas producen dos diferencias distintas.

EFFECTO MARGINAL DE AÑADIR RoPE

$$\Delta_{\text{add RoPE}} = M(\text{sinusoidal} + \text{RoPE}) - M(\text{sinusoidal})$$

COMPARACIÓN ENTRE ESTRATEGIAS


$$\Delta_{\text{strategy}} = M(\text{RoPE only}) - M(\text{sinusoidal only})$$

Mantener constantes: datos, semilla, arquitectura, optimizador, presupuesto y métrica.

Lectura: cambiar una sola variable permite atribuir la diferencia al factor que estamos estudiando.

3A. Dónde entra la información posicional

Las estrategias posicionales modifican lugares distintos del cálculo.



Pregunta al aula: si reemplazo RoPE por ALiBi, ¿qué parte del forward debe cambiar?

Lectura: no todas las estrategias de posición se suman a X; identifique dónde actúa cada una.

4. Proyecciones Q, K y V

La misma matriz X se proyecta en tres espacios aprendidos.

$$Q = XW_Q \quad K = XW_K \quad V = XW_V$$

PESOS

$$W_Q, W_K \in \mathbb{R}^{d_{\text{model}} \times d_k} \quad W_V \in \mathbb{R}^{d_{\text{model}} \times d_v}$$

FORMAS RESULTANTES


$$Q, K \in \mathbb{R}^{T \times d_k} \quad V \in \mathbb{R}^{T \times d_v}$$

Lectura: query busca compatibilidad, key se compara con la query y value aporta el contenido que se mezcla.

4A. Pasaporte de tensores

Antes de ejecutar, prediga la forma de cada objeto.

$B = 1$ $T = 4$ $d_model = 8$ $H = 2$ $d_head = 4$



Lectura: las formas son parte de la especificación; predígalas antes de mirar el resultado del notebook.

5. Ejemplo numérico: X y matrices de proyección

Tres posiciones y dimensión 2 para poder seguir cada multiplicación.

$$X = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$$

$$W_Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$W_K = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

$$W_V = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$$

t0 = <BOS>

t1 = the

t2 = llama

Lectura: el objetivo no es dar semántica a las coordenadas, sino hacer visible la mecánica matricial.

6. Ejemplo numérico: Q, K y V resultantes

Multiplicamos X por cada matriz aprendida.

QUERY	KEY	VALUE
$Q = XW_Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$	$K = XW_K = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 2 \end{bmatrix}$	$V = XW_V = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 2 & 1 \end{bmatrix}$

Cada fila de Q se comparará con todas las filas de K.

Lectura: Q y K determinan compatibilidad; V contiene lo que finalmente será combinado.

7. Producto QK^T : matriz de compatibilidad

Cada fila es una query; cada columna es una key.

$$QK^T = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 2 & 1 & 3 \end{bmatrix}$$

FORMA

$$(T \times d_k)(d_k \times T) = T \times T$$

FILA DE LA POSICIÓN 2

$$[2, 1, 3]$$

Lectura: la tercera query es más compatible con la tercera key porque 3 es el score mayor de esa fila.

8. Escala por sqrt(d_k)

Antes de softmax controlamos la magnitud de los productos punto.

$$S = \frac{QK^\top}{\sqrt{d_k}}$$

$$d_k = 2 \quad \sqrt{d_k} = \sqrt{2} \approx 1.4142$$

SCORES ESCALADOS

$$S \approx \begin{bmatrix} 0.707 & 0.000 & 0.707 \\ 0.707 & 0.707 & 1.414 \\ 1.414 & 0.707 & 2.121 \end{bmatrix}$$

SIN ESCALA

$$\text{softmax}([2, 1, 3]) \approx [0.245, 0.090, 0.665]$$

CON ESCALA

$$\text{softmax}\left(\frac{[2, 1, 3]}{\sqrt{2}}\right) \approx [0.284, 0.140, 0.576]$$

Lectura: la distribución escalada es menos extrema y evita llevar softmax demasiado pronto a saturación.

9. Máscara causal

Una posición i no puede usar una posición futura $j > i$.

REGLA

$$M_{ij} = \begin{cases} 0, & j \leq i \\ -\infty, & j > i \end{cases}$$

MATRIZ

$$M = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 0 & -\infty \\ 0 & 0 & 0 \end{bmatrix}$$

LOGITS ENMASCARADOS

$$S_{\text{causal}} = S + M \approx \begin{bmatrix} 0.707 & -\infty & -\infty \\ 0.707 & 0.707 & -\infty \\ 1.414 & 0.707 & 2.121 \end{bmatrix}$$

posición futura -> logit = -inf -> softmax -> peso = 0

$$e^{-\infty} = 0$$

Lectura: la causalidad se impone antes de softmax, modificando el conjunto de posiciones permitidas.

10. Softmax y salida de atención

Los logits se normalizan fila por fila y luego mezclan los valores.

PESOS

$$A_{\text{causal}} = \text{softmax}(S_{\text{causal}}) \approx \begin{bmatrix} 1.000 & 0.000 & 0.000 \\ 0.500 & 0.500 & 0.000 \\ 0.284 & 0.140 & 0.576 \end{bmatrix}$$

SALIDA

$$O = A_{\text{causal}}V \approx \begin{bmatrix} 1.000 & 0.000 \\ 1.000 & 0.500 \\ 1.576 & 0.716 \end{bmatrix}$$

$$o_0 = 1.0v_0$$

$$o_1 = 0.5v_0 + 0.5v_1$$

$$o_2 \approx 0.284v_0 + 0.140v_1 + 0.576v_2$$

Lectura: atender significa construir una combinación ponderada de los valores permitidos.

11. Ecuación completa e invariantes

Una fórmula compacta, dos propiedades que podemos medir.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V$$

NORMALIZACIÓN

$$E_{\text{norm}} = \max_i \left| \sum_j A_{ij} - 1 \right|$$

LEAKAGE FUTURO

$$L_{\text{future}} = \max_{j>i} A_{ij}$$

Causal attention: $E_{\text{norm}} \approx 0$ y $L_{\text{future}} \approx 0$

Lectura: softmax puede normalizar correctamente incluso cuando existe atención hacia posiciones futuras.

11A. Dos invariantes, dos propiedades

Normalización y causalidad responden preguntas diferentes.

CONFIGURACIÓN	E_norm	L_future	INTERPRETACIÓN
causal	≈ 0	≈ 0	normaliza y bloquea posiciones futuras
full	≈ 0	> 0	normaliza, pero puede asignar peso al futuro

¿Por qué softmax no basta para garantizar causalidad?

Lectura: una métrica puede estar correcta mientras otra propiedad del componente falla.

12. Multi-Head Attention

Cada head aprende proyecciones propias y produce una mezcla distinta.

DIMENSIÓN POR HEAD

$$d_{\text{head}} = \frac{d_{\text{model}}}{H}$$

PROYECCIONES POR HEAD

$$Q_h = XW_Q^{(h)} \quad K_h = XW_K^{(h)} \quad V_h = XW_V^{(h)}$$

CADA HEAD

$$\text{head}_h = \text{Attention}(Q_h, K_h, V_h)$$

COMBINACIÓN

$$\text{MHA}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_H)W_O$$


EJEMPLO: B=2, T=10, d_model=64, H=4

$$[B, H, T, d_{\text{head}}] = [2, 4, 10, 16]$$

Lectura: tener varios heads no fija su función semántica; solo les da proyecciones independientes.

12A. Reshape de Multi-Head Attention


La matemática es compacta; la implementación debe hacer explícito el layout de tensores.



Lectura: cada head produce una matriz $T \times T$ de compatibilidad y vuelve a d_model después de concatenar.

13. Dos heads: dos mezclas para las mismas posiciones

Mismos tokens, distintos Q/K/V aprendidos.




La concatenación recupera $d_{\text{model}} = 4$.

Lectura: las dos cabeceras producen combinaciones distintas antes de volver al espacio del modelo.

14. Proyección de salida W_O

Después de concatenar, W_O mezcla la información de todos los heads.



W_O no es decorativa: transforma la concatenación y devuelve una representación en d_{model} .

Lectura: MHA termina en una proyección aprendida que vuelve a mezclar las características de los heads.

15. Residual y LayerNorm

El bloque pre-norm conserva un camino directo y normaliza antes de MHA.

$$Y = X + \text{MHA}(\text{LN}(X))$$

LAYERNORM

$$\text{LN}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$$

MEDIA Y VARIANZA

$$\mu = \frac{1}{d_{\text{model}}} \sum_{k=1}^{d_{\text{model}}} x_k \quad \sigma^2 = \frac{1}{d_{\text{model}}} \sum_{k=1}^{d_{\text{model}}} (x_k - \mu)^2$$

EJEMPLO

$$x = [2.0, 0.0, 1.0, 3.0] \Rightarrow \text{LN}(x) \approx [0.447, -1.342, -0.447, 1.342]$$

RESIDUAL

$$m = [0.4, -0.2, 0.1, 0.3] \Rightarrow y = x + m = [2.4, -0.2, 1.1, 3.3]$$

Lectura: LayerNorm actúa sobre características de una posición; attention es quien mezcla información entre posiciones.

16. FFN y bloque Transformer pre-norm

Attention mezcla posiciones; FFN transforma cada posición por separado.

$$\text{FFN}(x) = W_2 \text{GELU}(W_1 x + b_1) + b_2$$

FORMAS

$$W_1 \in \mathbb{R}^{4d_{\text{model}} \times d_{\text{model}}}$$

$$W_2 \in \mathbb{R}^{d_{\text{model}} \times 4d_{\text{model}}}$$

d_model = 64 -> 256 -> GELU -> 64

SUBBLOQUE 1

$$Y = X + \text{MHA}(\text{LN}(X))$$

SUBBLOQUE 2

$$Z = Y + \text{FFN}(\text{LN}(Y))$$

Lectura: el Transformer alterna interacción entre tokens y transformación local de características.

17. Encoder-decoder y cross-attention

La query viene del decoder; keys y values vienen del encoder.

ENCODER

$$H_E = \text{Encoder}(X_{\text{source}})$$

PROYECCIONES

$$Q_D = H_D W_Q^{\text{cross}} \quad K_E = H_E W_K^{\text{cross}} \quad V_E = H_E W_V^{\text{cross}}$$

$$\text{CrossAttention}(Q_D, K_E, V_E) = \text{softmax}\left(\frac{Q_D K_E^\top}{\sqrt{d_k}}\right) V_E$$

fuentes completa -> encoder

K_E, V_E

decoder causal -> nueva
secuencia

Lectura: cross-attention conecta el estado parcial del decoder con la representación completa de la fuente.

18. Decoder-only: probabilidad autoregresiva

El modelo factoriza la secuencia en predicciones del siguiente token.

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t \mid x_1, \dots, x_{t-1})$$

SIGUIENTE TOKEN

$$P(x_t \mid x_{<t}) = P(x_t \mid x_1, \dots, x_{t-1})$$

LM HEAD

$$z_t = W_{\text{vocab}} h_t + b$$

[Lima, Cusco, Arequipa]

$$z = [4.2, 1.1, 0.5] \Rightarrow \text{softmax}(z) \approx [0.935, 0.042, 0.023]$$

Lectura: la máscara causal evita que la posición que predice Lima consulte directamente el token Lima del futuro.

19. Full attention vs causal attention

La triangularidad es la consecuencia visual de una restricción algebraica.

FULL ATTENTION

$$A_{\text{full}} = \begin{bmatrix} * & * & * & * \\ & * & * & * \\ & & * & * \\ & & & * \end{bmatrix}$$

CAUSAL ATTENTION

$$A_{\text{causal}} = \begin{bmatrix} * & 0 & 0 & 0 \\ & * & 0 & 0 \\ & & * & * \\ & & & * \end{bmatrix}$$

$$j > i \implies A_{ij} = 0$$

Lectura: no memorice "causal = triángulo". Memorice la propiedad $j > i \rightarrow A_{ij} = 0$.

19A. De la ecuación al código

Localice cada operación matemática dentro de una implementación real.

MATEMÁTICA

$$Q = X W_Q \quad K = X W_K \quad V = X W_V$$

$$S = Q K^T$$

$$S = S / \sqrt{d_k}$$

$$S = S + M$$

$$A = \text{softmax}(S)$$

$$O = A V$$

$$\text{MHA} = \text{Concat}(\text{heads}) W_O$$

IMPLEMENTACIÓN

```
q = self.query(x); k = self.key(x); v = self.value(x)
```

```
scores = q @ k.transpose(-2, -1)
```

```
scores = scores / math.sqrt(d_k)
```

```
scores = scores.masked_fill(~mask, float("-inf"))
```

```
attn = torch.softmax(scores, dim=-1)
```

```
out = attn @ v
```


```
out = self.out_proj(concat_heads(out))
```

¿Dónde vive la causalidad? -> en la máscara aplicada antes del softmax

Lectura: paper -> ecuación -> tensor -> código -> propiedad -> métrica.

20. Mapa final de ecuaciones

Recorrido rápido para cerrar la sesión o volver a una fórmula específica.



MULTI-HEAD

$$\text{MHA}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_H)W_O$$

RESIDUAL 1

$$Y = X + \text{MHA}(\text{LN}(X))$$

RESIDUAL 2

$$Z = Y + \text{FFN}(\text{LN}(Y))$$

VERIFICACIÓN CAUSAL

$$L_{\text{future}} = \max_{j>i} A_{ij} \approx 0$$

Cierre: ecuación -> tensor -> código -> propiedad -> métrica -> visualización.