

CC-0F4


Ecuaciones esenciales

Semana 4

Embeddings, segmentación, recuperación densa y almacenes vectoriales

1. Del texto a la recuperación densa

El objetivo es recuperar automáticamente evidencia relevante antes de construir RAG.




PREGUNTA DE LA SEMANA

¿Qué fragmentos del corpus son más relevantes para una consulta?

Lectura: Semana 4 separa recuperación de generación: primero obtenemos top-k; todavía no generamos una respuesta.

2. Qué es un embedding

Un encoder transforma un texto en un punto de un espacio vectorial de dimensión fija.




Lectura: un embedding no es el texto: es una representación numérica aprendida para poder comparar consultas y fragmentos.

3. Pasaporte de tensores

Antes de ejecutar, prediga la forma de cada matriz que participa en la búsqueda.

$N = 1000$ fragmentos $B = 4$ consultas $d = 384$



INTERPRETACIÓN

S tiene una fila por consulta y una columna por fragmento indexado.

Lectura: las formas son parte de la especificación: $S[2, 17]$ es el score de la consulta 2 frente al fragmento 17.

4. Norma L2 y normalización

La normalización elimina la magnitud y conserva la dirección del vector.

NORMA L2

$$\|x\|_2 = \sqrt{\sum_{i=1}^d x_i^2}$$

NORMALIZACIÓN L2

$$\hat{x} = \frac{x}{\|x\|_2}$$
$$\|\hat{x}\|_2 = 1$$

EJEMPLO

$$x = [3, 4] \Rightarrow \|x\|_2 = 5 \Rightarrow \hat{x} = [0.6, 0.8]$$

Lectura: `normalize_embeddings=True` hace comparable el ángulo entre vectores y permite usar producto interno como coseno.

5. Similitud coseno: ejemplo numérico

La similitud depende del ángulo entre dos vectores, no de que sus componentes sumen algo específico.

VECTORES

$$x = (2, 1, 0)^T \quad y = (1, 2, 0)^T$$

PRODUCTO Y NORMAS

$$x^T y = 4$$
$$\|x\|_2 = \|y\|_2 = \sqrt{5}$$

COSENO

$$\cos(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2}$$
$$= \frac{4}{5} = 0.8$$

0.8 indica alta alineación angular; no significa 80% de probabilidad.

Lectura: el score de similitud ordena candidatos, pero no garantiza que un fragmento sea realmente relevante para la tarea.

6. Coseno, producto interno y distancia

Con vectores unitarios, tres expresiones quedan directamente relacionadas.

COSENO = PRODUCTO INTERNO

$$\hat{x}^T \hat{y} = \cos(x, y)$$

DISTANCIA ENTRE VECTORES UNITARIOS

$$\|\hat{x} - \hat{y}\|_2^2 = 2 - 2\cos(x, y)$$

CONSECUENCIA

Maximizar coseno <-> maximizar producto interno <-> minimizar distancia L2

Lectura: la equivalencia de ranking requiere la condición de normalización; sin ella, inner product y coseno no son lo mismo.


7. Recuperación exacta como operación matricial

Cada consulta se compara con todos los fragmentos indexados.

MATRIZ DE SCORES

$$S = QE^{\top} \in \mathbb{R}^{B \times N}$$
$$S_{ij} = q_i^{\top} e_j$$

Una fila de S contiene todos los scores de una consulta frente al corpus.



Lectura: NumPy con $Q @ E.T$ y FAISS IndexFlatIP deben producir el mismo ranking cuando ambos hacen la misma búsqueda exacta.

8. Ranking y top-k

Recuperar consiste en ordenar scores y conservar los primeros candidatos.

1. SCORE

$$s_i = s(q, e_i)$$

2. ORDENAMIENTO

$$s_{(1)} \geq s_{(2)} \geq \dots \geq s_{(N)}$$

3. TOP-K

$$R_k(q) = \text{TopK}_i s(q, e_i)$$

ADVERTENCIA

score alto != relevancia garantizada

Lectura: top-k es una política de selección; aumentar k mejora cobertura potencial, pero también puede introducir fragmentos menos relacionados.

9. Búsqueda exacta frente a aproximada

La escala del índice introduce un trade-off entre trabajo de búsqueda y calidad del vecino recuperado.

EXACT SEARCH - IndexFlatIP

compara contra todos los vectores

costo por consulta $\sim O(Nd)$

APPROXIMATE NEAREST NEIGHBORS

explora una parte del espacio

HNSW / IVF: ejemplos de índices ANN


TRADE-OFF

latencia <-> recall de búsqueda <-> memoria

Lectura: FAISS es una biblioteca con índices exactos y aproximados; IndexFlatIP en esta semana es deliberadamente exacto.

10. Segmentación: tamaño y overlap

La unidad indexada es el fragmento; cambiar su granularidad cambia qué información entra en cada embedding.



Lectura: más contexto por fragmento no implica mejor retrieval: puede conservar contexto útil o diluir la evidencia relevante.

11. Índice, almacén vectorial y recuperador

Las APIs pueden ocultar capas distintas; conviene separar responsabilidades y costos.

MEMORIA DE LOS VECTORES

$$M_{\text{vectors}} \approx Ndb$$

N: vectores d: dimensión b: bytes/componente

FAISS != modelo de embeddings

modelo de embeddings

produce vectores

métrica de similitud

define cercanía

índice

organiza y busca

almacén vectorial

vectores + ids + metadatos + persistencia

recuperador

política de evidencia

Lectura: Ndb estima solo la matriz de embeddings; no incluye metadatos, estructura del índice, buffers ni overhead del runtime.

12. Recall@k: cobertura de evidencia relevante

Esta semana usamos una métrica mínima; MRR y nDCG se reservan para la Semana 7.

DEFINICIÓN

$$\text{Recall}@k(q) = \frac{|G_q \cap C_k(q)|}{|G_q|}$$

EJEMPLO

$$\begin{aligned} G_q &= \{A, C, D\} \\ C_3(q) &= \{C, B, A\} \\ \text{Recall}@3 &= \frac{2}{3} \end{aligned}$$

PROMEDIO SOBRE CONSULTAS

$$\overline{\text{Recall}@k} = \frac{1}{|Q|} \sum_{q \in Q} \text{Recall}@k(q)$$

Lectura: Recall@k responde cuánta evidencia relevante quedó cubierta; no evalúa por sí solo calidad de generación ni utilidad final del sistema.

13. Experimento de Semana 4

Se cambia únicamente target_words y se mantienen fijas las demás condiciones del benchmark.

SMALL

100

BASELINE

180

LARGE

320

VARIABLES FIJAS

corpus, queries, qrels, overlap_passages = 1, modelo de embeddings, normalización L2, similitud = inner product, IndexFlatIP y top-k.

MÉTRICA PRINCIPAL

mean Recall@3


CAMBIO RESPECTO DEL BASELINE

$$\Delta_{small} = \overline{R@3}_{100} - \overline{R@3}_{180} \quad \Delta_{large} = \overline{R@3}_{320} - \overline{R@3}_{180}$$

Lectura: la conclusión debe limitarse a este corpus, estas consultas, estos qrels y este modelo; no se cambia la hipótesis después de mirar resultados.

14. Mapa final de ecuaciones - Semana 4

De texto a evidencia: representación, comparación, búsqueda y evaluación.



Lectura: Semana 4 prepara la recuperación densa; Semana 5 añadirá BM25, fusión, reranking y RAG.