

CC-0F4

Ecuaciones esenciales


Semana 5

BM25, recuperación híbrida, reranking y RAG

BM25 → RRF → Rerank → RAG

1. De recuperación densa a RAG híbrido

Semana 5 conserva el benchmark de Semana 4 y agrega señales y etapas de ranking.



Lectura: BM25 y dense retrieval producen candidatos; RRF fusiona rankings y el Cross-Encoder reordena un conjunto pequeño.

2. Sparse retrieval y dense retrieval

Dos familias de recuperación capturan señales distintas y pueden ser complementarias.

BM25 / SPARSE

Consulta y fragmento se comparan mediante términos.

Favorece coincidencia léxica, rareza documental, identificadores, siglas y entidades.

$$s_{\text{BM25}}(q, d)$$

DENSE / E5

Consulta y fragmento se transforman en embeddings.

La proximidad se calcula en el espacio vectorial heredado de Semana 4.

$$s_{\text{dense}}(q, d) = \hat{q}^{\top} \hat{e}_d$$

misma consulta -> dos señales -> posibles candidatos distintos

Lectura: Sparse no es dense con otra librería: representan y puntúan la evidencia de forma diferente.

3. BM25: anatomía del score

El score combina rareza, frecuencia, saturación y normalización por longitud.

ECUACION

$$\text{BM25}(q, d) = \sum_{t \in q} \text{IDF}(t) \frac{f(t, d)(k_1 + 1)}{f(t, d) + k_1 \left(1 - b + b \frac{|d|}{\text{avgdl}} \right)}$$

IDF(T)

rareza documental

F(T,D)

frecuencia del término

K1

saturación

B

efecto de longitud

Configuración canónica: k1 = 1.5 | b = 0.75

Lectura: No memorice la fórmula como un bloque: identifique que problema resuelve cada término.

4. IDF de Robertson: rareza documental

$df(t)$ cuenta en cuántos fragmentos aparece el término t ; N es el numero total de fragmentos.

IDF BRUTO

$$IDF_{\text{raw}}(t) = \log \frac{N - df(t) + 0.5}{df(t) + 0.5}$$

TERMINO RARO

$$N = 100, df = 5$$

IDF raw $\approx$ 2.85

MITAD DEL CORPUS

$$df \approx N/2$$

IDF raw $\approx$ 0

TERMINO MUY COMUN

$$N = 100, df = 80$$

IDF raw $\approx$ -1.37

$$df(t) / N > 0.5 \rightarrow IDF_{\text{raw}}(t) < 0$$

Lectura: La intuición "término raro = informativo" tiene una definición cuantitativa y también casos con IDF bruto negativo.

5. Saturación de frecuencia y longitud

Repetir un término ayuda cada vez menos; b controla cuánto influye la longitud del fragmento.

SATURACION TF

$$g(f) = \frac{f(k_1 + 1)}{f + K}$$
$$\lim_{f \rightarrow \infty} g(f) = k_1 + 1$$

NORMALIZACION POR LONGITUD

$$K(d) = k_1 \left(1 - b + b \frac{|d|}{\text{avgdl}} \right)$$

SI B = 0

$$K(d) = k_1$$

SI B = 1


$$K(d) = k_1 \frac{|d|}{\text{avgdl}}$$

más repeticiones != crecimiento lineal ilimitado del score

Lectura: k1 controla la saturación; b controla cuánto se corrige por longitud. En Semana 5 ambos quedan fijos.

6. La ecuación y la biblioteca no son exactamente lo mismo

rank_bm25.BM25Okapi aplica una política explícita cuando el IDF bruto resulta negativo.



Lectura: En particular, el curso conserva términos como "no" y "sin" porque eliminarlos puede cambiar la intención de una consulta.

7. Candidate generation y candidate_depth

El recuperador debe encontrar primero los candidatos que podrán ser fusionados y rerankeados.

BM25

$$C_B(q) = \text{TopK}_m \{ \text{BM25}(q, d_i) \}$$

DENSE

$$C_D(q) = \text{TopK}_m \{ \hat{q}^\top \hat{e}_i \}$$

UNION DE CANDIDATOS

$$C(q) = C_B(q) \cup C_D(q)$$

Semana 5: $m = \text{candidate_depth} = 10$

d^* no está en $C(q)$ -> el reranker no puede recuperarlo

Lectura: Con 24 fragmentos en el baseline docente, candidate_depth=10 cubre una fracción grande del corpus; no es un benchmark a gran escala.

8. BM25 score y dense score no comparten una escala

Sumar o promediar scores heterogéneos exige una calibración que el experimento no asume.

EJEMPLO BM25

$$s_{BM25} = 7.4$$

EJEMPLO DENSE

$$s_{dense} = 0.81$$

NO HAY INTERPRETACION AUTOMATICA

$$\frac{7.4 + 0.81}{2} \quad ?$$

solución de Semana 5: fusionar POSICIONES de ranking mediante RRF

Lectura: RRF evita comparar directamente magnitudes que provienen de funciones de score diferentes.

9. Reciprocal Rank Fusion (RRF)

Cada ranking aporta una contribucion que depende de la posición del candidato, no de su score original.

ECUACION GENERAL

$$\text{RRF}(d) = \sum_{r \in R} \frac{1}{k + r(d)}$$

DOS RECUPERADORES

$$\text{RRF}(d) = \frac{1}{k + r_{BM25}(d)} + \frac{1}{k + r_{dense}(d)}$$

Semana 5: k = 60

Lectura: RRF utiliza rankings. Un candidato bien ubicado por ambos recuperadores acumula dos contribuciones.

10. Ejemplo numérico de RRF

El mismo $k=60$ permite comparar candidatos sin mezclar directamente BM25 score y dense inner product.

CANDIDATO A

BM25 rank = 2 | Dense rank = 4

$$RRF(A) = \frac{1}{62} + \frac{1}{64} \approx 0.03175$$

CANDIDATO B

BM25 rank = 1 | Dense: no aparece

$$RRF(B) = \frac{1}{61} \approx 0.01639$$

A obtiene apoyo de dos rankings y supera a B en este ejemplo

RRF no inventa candidatos: si no aparece en ninguna lista, no puede fusionarlo

Lectura: La fusion cambia el orden de candidatos existentes; no reemplaza la calidad de candidate generation.

11. Bi-encoder frente a Cross-Encoder

El primero permite indexar; el segundo puntúa conjuntamente cada par consulta-fragmento.

BI-ENCODER

query -> encoder -> e_q

fragmento -> encoder -> e_d

$$s(q, d) = e_q^\top e_d$$

e_d puede precomputarse

CROSS-ENCODER

[query ; fragmento] -> Transformer

$$s_{CE}(q, d) = g_\phi(q, d)$$

requiere inferencia por cada par

corpus grande -> retriever -> pocos candidatos -> Cross-Encoder

Lectura: Semana 5 usa cross-encoder/mmarco-mMiniLMv2-L12-H384-v1 solo sobre el conjunto pequeño de candidatos.

12. Retrieve then rerank: qué puede corregir

El reranker puede cambiar posiciones dentro de $C(q)$, pero no puede rescatar evidencia ausente.


CASO CORREGIBLE

$$d^* \in C(q)$$
$$\text{rank}(d^*): 7 \rightarrow 1$$

CASO NO CORREGIBLE

$$d^* \notin C(q)$$

el Cross-Encoder nunca lo recibe




candidate recall limita el techo de lo que el reranker puede ordenar

Lectura: Recuperación y reranking son etapas distintas: una genera candidatos y la otra refina su orden.

13. De ranking a RAG

RAG agrega evidencia recuperada al contexto de entrada; no convierte retrieval y generation en la misma tarea.



Recall@k sube != calidad de la respuesta RAG sube automaticamente

retrieval correcto + generación incorrecta -> respuesta incorrecta

Lectura: Una respuesta correcta tampoco demuestra por si sola que el retriever sea bueno: el LLM puede usar conocimiento paramétrico.

14. Experimento principal de Semana 5

Mismo corpus, consultas, qrels, chunking y top-k; cambia la estrategia de recuperación/reranking.

CONDICION A

BM25_stopwords

CONDICION B

Dense E5 + FAISS

CONDICION C

Hybrid + RRF

CONDICION D

Hybrid + RRF + CE

METRICA PRINCIPAL

mean Recall@3 (también Recall@1 y Recall@5)

CAMBIO DENSO -> HIBRIDO

$$\Delta_{C-B} = \overline{R@3}_C - \overline{R@3}_B$$

EFECTO INCREMENTAL DEL RERANKER


$$\Delta_{D-C} = \overline{R@3}_D - \overline{R@3}_C$$

El cuaderno también registra latencia media/p95 y bootstrap pareado de Recall@3.

Lectura: D-C aísla de forma más limpia el efecto incremental del reranker; B-C agrega BM25 y fusion simultaneamente.

15. Mapa final de ecuaciones - Semana 5

Del score léxico a la respuesta: candidate generation, fusión, reranking y uso de evidencia.



Lectura: Cierre: señal sparse + señal dense -> fusión -> reranking -> evidencia -> contexto -> generación -> evaluación.